

新疆大学研究生课程考试（查）论文

2024——2025 学年 第二学期

《融合 Mamba 的多认知 PCB 缺陷检测算法》

课程名称: 深度学习实践

任课教师: 程述立

学 院: 计算机科学与技术学院

专 业: 计算机技术

学 号: 107552403925

姓 名: 靳凌霄

成 绩:

评语:

目 录

摘要	2
第一章 项目概述	3
1.1 引言	3
1.2 相关工作	4
第二章 模型设计与实现	5
2.1 方法	5
2.1.1 预备知识	5
2.1.2 PCB-MMDET 总架构	6
2.1.2 TSMR 模块	7
2.1.2 MC-VAM 模块	8
2.1.2 LGSD 检测头	8
第三章 模型测试与分析	11
3.1 数据集	11
3.1.1 PCB_DATASET 数据集	11
3.1.2 DeepPCB 数据集	11
3.1.3 DsPCBSD+数据	12
3.2 实验环境	13
3.3 评价指标	13
3.4 实验过程	14
3.1.1 PCB_DATASET 数据集下对比实验	14
3.1.2 PCB_DATASET 数据集下消融实验	15
3.1.3 DeepPCB 数据集下对比实验	16
3.1.4 DeepPCB 数据集下消融实验	17
3.1.5 DsPCBSD+数据集下对比实验	18
3.1.4 DsPCBSD+数据集下消融实验	20
3.5 实验可视化展示	21
3.5 实验结论	23
第四章 创新性说明	24
第五章 课程总结	25
参考文献	26

摘要

印制电路板 (Printed Circuit Board, PCB) 表面纹理复杂、缺陷特征目标小、类别复杂且难以区分, 传统检测方法在精度和鲁棒性方面存在局限, 现有的基于深度学习的方法仍存在微小目标特征提取能力不足、特征信息冗余、模型复杂度高问题, 为此, 提出融合 Mamba 的多认知改进 YOLO11 缺陷检测模型 PCB-MMDet。该模型在骨干网络部分设计并嵌入三阶段多感受野特征融合模块 (Three-Stage Multi-Receptive Module, TSMR), 以融合长程小波变换增强 Mamba 模块 (Long-Range Wavelet Transform-Enhanced Mamba Module, LRWTE-Mamba) 与多核深度卷积模块 (Multi-Kernel Depthwise Convolution Module, MK-DeConv) 的方式结合全局建模与高频边缘信息提取并增强局部感受野, 从而提高模型对 PCB 电路板微小缺陷特征的识别能力, 并通过部分边缘信息恒等映射的方式减少高维空间中的特征冗余以降低模型复杂度。在颈部网络部分, 设计并嵌入多认知视觉增强模块 (Multi-Cognitive Visual Augmentation Module, MC-VAM), 通过自适应加权融合多尺度特征, 以增强对主干网络信息的利用, 使模型能够精准关注关键缺陷区域。此外, 将 YOLO11 的检测头替换为轻量化群共享小目标检测头 (Lightweight Group-Shared Detection Head, LGSD), 通过群归一化共享参数的方式优化边界框的界定, 有效减少模型的计算量。实验结果表明, PCB-MMYOLO 模型在 PCB_DATASET 缺陷数据集中的多个指标均表现优异, 其 mAP50 值达到 93.3%, 较基准模型提升 2.8%, 召回率达到 90.5%, 较基准模型提升 3.0%, 在 DeepPCB 数据集上 mAP50 值达到 98.2%; 在 DsPCBSD+数据集上 mAP50 值达到 88.2%, 同时, 参数量下降 9.15%, 计算量下降 12.60%, 均实现了当前领域最优性能。

关键词: 印制电路板; 小目标检测; 多感受野特征融合; 多认知视觉增强

第一章 项目概述

1.1 引言

随着信息技术的快速发展,电子产品普及度与集成度持续提升,印制电路板 (PCB) 作为核心组件,其性能稳定性和抗干扰能力面临更高要求。然而,PCB 制造过程中因元件微型化、工艺复杂性及环境因素(机械摩擦/静电干扰/化学腐蚀等),极易产生缺孔、鼠咬、开路及短路等缺陷^[1]。此类缺陷直接威胁电子设备的可靠性与安全性,亟需通过精准检测实现质量控制。

传统 PCB 缺陷检测方法(人工目检、电气测试、红外成像等)普遍存在效率低、损伤风险高、可检缺陷类型有限等问题。非接触式的自动光学检测(Automated Optical Inspection, AOI)技术因此迅速发展,其核心算法可分为两类:基于传统机器视觉的方法与基于深度学习的方案。

为实现 PCB 自动检测,研究者提出了多种基于传统机器视觉的 PCB 缺陷检测方法。Baygin 等人^[2]结合 Hough 变换和 Canny 算子提取图像特征,通过参考图与测试图匹配精准检测缺孔缺陷。Wong^[3]等人利用调频连续波大赫兹成像技术对 PCB 图像进行增强,并结合 sync 卷积和盲反卷积方法,有效提升了图像的增强效果。朱寒等人^[4]采用改进 Sobel 算子提取边缘信息,结合二值化与中值滤波实现 PCB 区域的精准定位。但基于传统机器视觉的检测方法受环境光线、成像条件、图像精度等因素以及算法泛化能力的限制,鲁棒性欠佳,易引发漏检、误检等问题,需要人工后期校正。

相比之下,基于深度学习的 PCB 缺陷检测技术具有更好的特征提取能力和模型泛化能力,通过大量学习缺陷样本,能够显著提升 PCB 缺陷的检测效果。Dong 等人^[5]提出了基于 Faster R-CNN 的 TDD-net,使用 K-means 聚类方法获得更合理的锚框和不同层次的增强特征映射关系,适用于 PCB 表面缺陷的检测。Xiao 等人^[6]在坐标注意力机制改进 YOLOv7-tiny 的骨干,增强模型的特征提取能力,从而提高模型检测精度。Li 等人^[7]设计了一种基于 Transformer 的检测模型,该模型使用多尺度特征来提升微小缺陷的检测效果。Li 等人^[8]引入了选择性特征增强模块,该模块专注于前景信息,抑制不相关信息,从而有效利用缺陷样本中的信息。谢翔等人^[9]结合 CBAM 注意力机制提高了小目标检测精度,并通过 GhostConv 卷积实现模型轻量化。

尽管上述方法提升了检测效果,但仍存在问题需要进一步解决,具体如下:(1)微小目标特征提取能力不足,特征信息利用率低,冗余信息多导致模型复杂度偏高。(2)在特征融合阶段中,包含丰富细节信息的浅层特征参与度不足,导致小目标的检测效果差。(3)在边界框界定阶段中,模型计算量过高,无法满足边缘设备部署要求。

为了解决上述问题,本文选择 YOLO11 作为基础模型,提出融合 Mamba 的多尺度改进 YOLO11 缺陷检测模型 PCB-MMDet。主要工作如下:

(1)在骨干网络部分设计并嵌入三阶段多感受野特征融合模块(Three-Stage Multi-Receptive Module, TSMR),以融合长程小波变换增强 Mamba 模块(Long-Range Wavelet Transform-Enhanced Mamba Module, LRWTE-Mamba)与多核深度卷积模块(Multi-Kernel Depthwise Convolution Module, MK-DeConv)的方式结合全局建模与高频边缘信息提取并增强局部感受野,从而提高模型对 PCB 电路板微小缺陷特征的识别能力,并通过部分边缘信息恒等映射的方式减少高维空间中的特征冗余以降低模型

复杂度。

(2)在颈部网络部分，设计并嵌入多认知视觉增强模块（Multi-Cognitive Visual Augmentation Module, MC-VAM），通过自适应加权融合多尺度特征，以提高主干网络信息的利用率，使模型能够精准关注关键缺陷区域。

(3)将 YOLO11 的检测头替换为轻量化群共享小目标检测头（Lightweight Group-Shared Detection Head, LGSD）。通过群归一化共享参数的方式优化边界框的界定，有效减少模型的计算量。

1.2 相关工作

实时目标检测器：YOLO 早期性能的改进与主干网络的改进密切相关，这导致了 DarkNet^[10]的广泛采用。YOLOv7（Wang 等，2023）^[11]提出了 E-ELAN 结构以增强模型能力而不破坏原有结构。YOLOv8（Jocher 等，2023）^[12]结合了之前 YOLOs 代的特征，并采用了 CSPDarknet53。两阶段 FPN（C2f）（Jocher 等，2023）^[13]结构具有更丰富的梯度流，既轻量又适应不同场景，同时考虑准确性。最近，Gold YOLO（Wang 等，2024）^[14]引入了一种名为 Gather-and-Distribute（GD）的新机制，通过自注意力操作解决传统特征金字塔网络（Lin 等，2017）和 Rep-PAN（Li 等，2022）^[15]的信息融合问题，并成功实现了 SOTA。

端到端目标检测器：DETR（Carion 等，2020）^[16]首次将 Transformer 引入目标检测，使用 Transformer 编码器-解码器架构绕过传统的手工制作组件，如锚点生成和非最大抑制，将检测视为直接的集成预测问题。Deformable DETR（Zhu 等，2020）^[17]引入了 Deformable Attention，一种 Transformer Attention 的变体，用于在参考位置周围采样一组稀疏的关键点，解决了 DETR 在处理高分辨率特征图时的局限性。DINO（Zhang 等，2022）^[18]整合了混合查询选择策略、可变形注意力，并证明了通过查询优化实现的训练中注入噪声和性能提升。RT-DETR（Zhao 等，2023）^[19]提出了一种混合编码器，将尺度内交互和跨尺度融合解耦，以实现高效的多尺度特征处理。然而，DETRs 的优异性能严重依赖于大规模数据集上的预训练操作，并且 DETRs 在训练收敛、计算成本和小目标检测方面的挑战，YOLOs 仍然是小模型领域中的 SOTA，兼顾准确性和速度。

基于视觉状态空间模型：基于 SSM（Gu, Goel, 和 Ré 2022; Gu 等，2021; Smith, Warrington, 和 Linderman 2023）^[20]的研究，Mamba（Gu 和 Dao 2023）显示出输入大小的线性复杂性，并解决了 Transformer 在长序列建模状态空间上的计算效率问题。在广义视觉主干领域，Vision Mamba（Zhu 等，2024）提出了一个基于选择性 SSM 的纯视觉主干模型，标志着 Mamba 首次被引入视觉领域。VMamba（Liu 等，2024）^[21]引入了 Cross-Scan 模块，使模型能够进行 2D 图像选择性扫描，增强视觉处理，并在图像分类任务上表现出优越性。LocalMamba（Huang 等，2024）^[22]专注于视觉空间模型的窗口扫描策略，优化视觉信息以捕获局部依赖性，并引入动态扫描方法为不同层搜索最优选择。受 VMamba 在视觉任务领域取得的显著成果的启发，本文首次提出 Mamba YOLO，一种新的 SSM 模型，与传统基于 SSM 的视觉主干不同，它不需要在大规模数据集（例如 ImageNet（Deng 等，2009）、Object365（Shao 等，2019））^[23]上进行预训练，旨在考虑全局感官场，同时展示其在目标检测中的潜力。

第二章 模型设计与实现

2.1 方法

2.1.1 预备知识

结构化状态空间序列模型 S4 (Gu, Goel, 和 R'e 2022) 和 Mamba (Gu 和 Dao 2023), 源于状态空间模型 (SSM) [24], 都源自于一个连续系统, 该系统通过一个隐式中间状态 $h(t) \in \mathbb{R}^N$ 将一个单变量序列 $x(t) \in \mathbb{R}$ 映射到输出序列 $y(t)$ 。这种设计不仅连接了输入和输出之间的关系, 还封装了时间动态。该系统可以用以下数学公式定义:

$$h'(t) = Ah(t) + Bx(t) \quad (1)$$

$$y(t) = Ch(t) \quad (2)$$

在方程 (1) 中, $A \in \mathbb{R}^{N \times N}$ 表示状态转移矩阵, 它控制隐藏状态随时间的演变, 而 $B \in \mathbb{R}^{N \times 1}$ 表示输入空间与隐藏状态相关的权重矩阵。此外, $C \in \mathbb{R}^{N \times 1}$ 是观测矩阵, 它将隐藏的中间状态映射到输出。Mamba 将这个连续系统应用于离散时间序列数据, 通过采用固定的离散化规则将参数 A 和 B 转换为它们的离散对应物 \bar{A} 和 \bar{B} , 从而更好地将系统整合到深度学习架构中。为此目的常用的离散化方法是零阶保持 (ZOH)。离散化版本可以定义如下:

$$\bar{A} = \exp(\Delta A) \quad (3)$$

$$\bar{B} = (\Delta A)^{-1}(\exp(\Delta A) - I)\Delta B \quad (4)$$

在方程 (4) 中, Δ 表示一个时间尺度参数, 它调整模型的时间分辨率, ΔA 和 ΔB 分别表示给定时间间隔内连续参数的离散时间对应物。这里, I 表示单位矩阵。变换后, 模型通过线性递归形式计算, 可以定义如下:

$$h'(t) = \bar{A}h_{t-1} + \bar{B}x_t \quad (5)$$

$$y_t = Ch_t \quad (6)$$

整个序列转换也可以表示为卷积形式，定义如下：

$$\mathbf{K} = (C\bar{B}, C\bar{A}\bar{B}, \dots, C\bar{A}^{L-1}\bar{B}) \quad (7)$$

$$\mathbf{y} = \mathbf{x} \times \bar{\mathbf{K}} \quad (8)$$

其中， $\bar{\mathbf{K}} \in R^L$ 表示结构化卷积核， L 表示输入序列的长度。在本文中提出的设计中，模型采用卷积形式进行并行。

2.1.2 PCB-MMDET 总架构

模型采用三阶段端到端目标检测网络结构，分为主干网络、颈部网络和检测头三部分。其中主干网络负责从输入图像中提取多层次特征，采用双层特征提取网络结构以减少计算冗余，同时增强梯度流动。具体而言，主干网络采用一种混合 CNN 与 Mamba 的特征提取方式，融合浅层与深层的特征信息以捕捉更丰富的语义信息，加强对小目标和复杂背景的特征表达能力并具有更强鲁棒性^[25]。然后经由 SPFF 传递给 MC-VAM，通过多认知特征融合的方式使模型关注核心缺陷区域。颈部网络有效整合来自不同层的特征图，从而增强模型对多尺度目标的感知能力。同时，引入轻量化的基于群归一化 GroupNorm 和共享卷积的轻量化检测头 LGSD，LGSD 检测头充分利用了 GroupNorm 和共享卷积的优势，能够在保持特征信息有效融合的情况下，尽量减少计算量和运算复杂度。

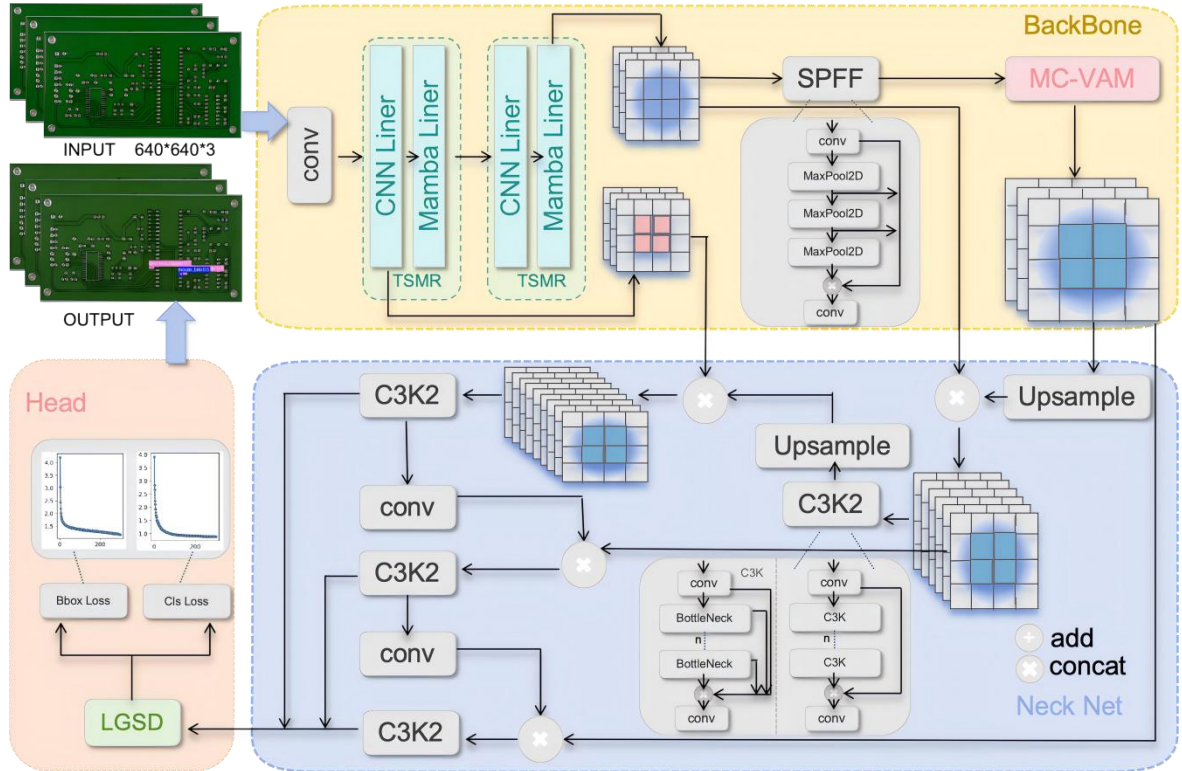


图 1 PCB-MMDET总架构图

2.1.2 TSMR 模块

TSMR 模块主要采用 CNN 与 Mamba 混合的方式，将模块分为 CNN 层与 Mamba 层。其中，CNN 层主要负责局部特征提取，Mamba 层负责构建全局特征关系。Mamba 层采用三阶段特征提取结构，第一部分通过双向扫描 Mamba (Bi-Mamba) 模块处理，以增强高频边缘信息的提取并进行全局建模。第二部分通过多核深度卷积 (MK-DeConv) 操作处理，通过不同大小的卷积核提取局部信息，实现多感受野交互。对于剩余特征，选择局部通道比例^[26]，并将这些通道分为 n 部分，每部分通过不同大小的卷积核^[27]进行处理，最后将不同卷积操作的结果拼接形成输出特征。第三部分通过恒等映射减少高维空间中的特征冗余，降低计算复杂度，提高处理速度。其中高效多核解卷积 (Efficient MK-DeConv) ^[28]通过具有不同有效感受野的卷积核提取局部信息，实现多感受野交互^[29]。对于剩余特征（其中局部通道比例 $\mu \leq 1 - \xi$ ），将其划分为 $n \in N$ 部分。每一部分采用不同核大小的局部卷积操作，最终将结果拼接形成输出特征。公式如下

$$x_{Lj}^O = \text{Conv}(x_{Lj}^I, \mathbf{k} = (2j + 1)), j \in 1, \dots, n. \quad (9)$$

$$x_L^O = \text{Concat}([x_{L1}^O, \dots, x_{Ln}^O], \text{dim} = -1) \quad (10)$$

最后，为减少高维空间中的特征冗余问题^[18]，我们对剩余的 $(1 - \xi - \mu)c$ 通道应用恒等映射。恒等映射^[30]的通道数：

$$(1 - \xi - \mu)c \quad (11)$$

该方法通过最小化不必要的计算来提升运算效率。经 TSMR 模块处理后的最终输出计算如下：

$$x^O = \text{Concat}(x_G^O, x_L^O, x^I[(1 - \xi - \mu)c:]) \quad (12)$$

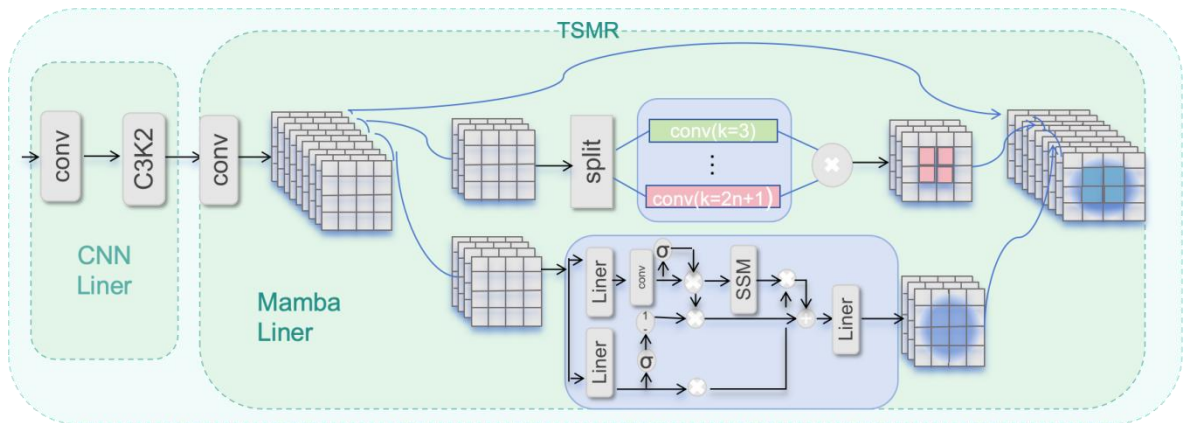


图 2 TSMR 模块架构图

2.1.2 MC-VAM 模块

MC-VAM 模块的核心在于引入了多认知视觉滤波器，这些滤波器通过多尺度卷积、动态归一化和深度残差^[31]设计大幅提升了视觉任务的迁移能力，以此增强适配器对视觉信号的处理能力。主要过程如下：

输入特征首先会进行 LayerNorm^[32]和可学习缩放：

$$x_{\text{norm}} = s_1 \cdot |x_0|_{\text{LN}} + s_2 \cdot x_0 \quad (13)$$

将输入特征维度降维到 adapter^[33]的低维空间：

$$f_{\text{down}} = D^l(x_{\text{norm}}) \quad (14)$$

通过三个不同 kernel size (3×3 、 5×5 、 7×7) 的 DWConv (深度可分离卷积) 处理多尺度特征：

$$f_{\text{dw}} = x + \text{avg} \left(\sum_{i=1}^3 \omega_{\text{dw}}^i \otimes \hat{x} \right) \quad (15)$$

使用 1×1 卷积进一步融合不同尺度下的特征：

$$f_{\text{pw}} = x + \omega_{\text{pw}} \otimes x \quad (16)$$

非线性激活 + 上采样^[34]，恢复回原始维度^[35]：

$$x = x_0 + U^l \sigma(f_{\text{pw}}(f_{\text{dw}}(f_{\text{down}}))) \quad (17)$$

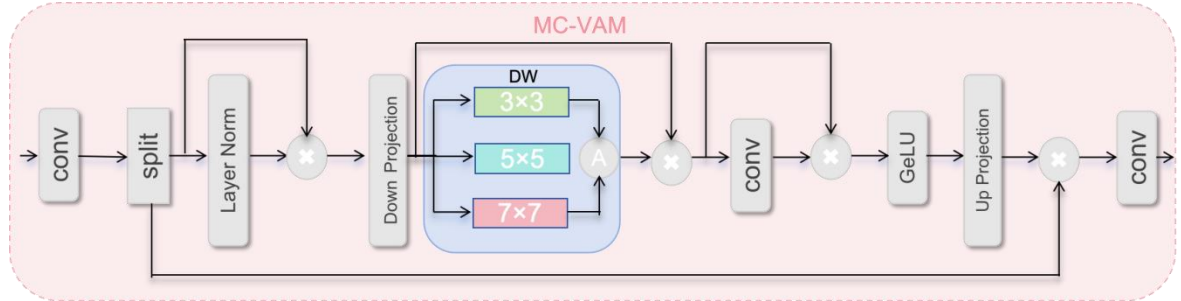


图 3 MC-VAM 模块架构图

2.1.2 LGSD 检测头

在深度学习网络中，为了加速模型的收敛速度、提高泛化能力、防止梯度消失或爆炸，一般需要对数据进行归一化处理，常用的归一化处理技术是批归一化 BatchNorm。BatchNorm 具有以下优点：(1) 通过增大学习率，加快模型收敛至最佳参数，减少训练时间；(2) 减少对初始权重的敏感性，帮助模型在不同初始值下保持相似性能；(3) 减少了对如 Dropout^[36]等正则化技术的依赖，降低过拟合风险；(4) 调整激活值分布^[37]，防止梯度消失或爆炸，使训练更稳定。虽然 BatchNorm^[38]具有很多优点，但是对 batch size 的大小比较敏感，由于每次计算均值和方差是在一个 batch 上进行的，所以如果 batch size 太小，则计算的均值和方差可能不足以代表整个数据分布，可能导致模型性能下降。本文选择使用 GroupNorm^[39]代替 BatchNorm 主要是因为

GroupNorm 具有更好的适应性、能够保持通道之间的相对关系、提高模型的鲁棒性、在一些场景下性能更佳以及减少对小批量大小的依赖等优点[14]。另外，在文献[15]中已经证明在处理一些目标检测任务中，GroupNorm 可以提升检测头定位和分类的性能。本文设计了一种基于群归一化 GroupNorm 和共享卷积的轻量化检测头 LGSD，其网络结构如图 5 所示。LGSD 检测头充分利用了 GroupNorm 和共享卷积的优势，能够在保持特征信息有效融合的情况下，尽量减少计算量和运算复杂度。

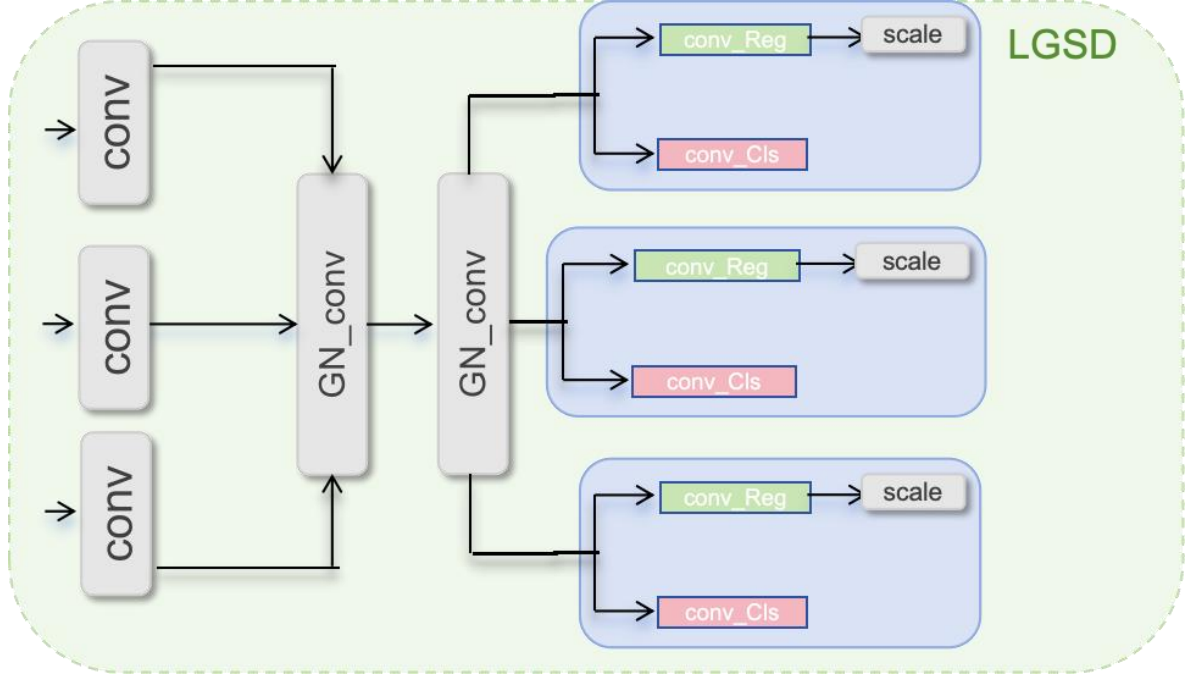


图 4 LGSD 模块架构图

在图 5 所示的 LSCD 检测头网络结构中，GN_Conv 1×1 模块表示的是群归一化 GroupNorm + 卷积 Conv 操作，其中 1×1 表示卷积核大小为 1×1 。三个蓝色预测框卷积模块 Conv_Box 共享权重，三个红色分类卷积模块 Conv_Cls 共享权重。在每个 Conv_Box 模块后面连接着 Scale 模块，Scale 模块主要是一个缩放系数，用来匹配对不同尺度目标的检测。归一化的公式如下所示：

$$\begin{aligned} \mu_i &= \frac{1}{m} \sum_{k \in S_i} x_k \\ \sigma_i &= \sqrt{\frac{1}{m} \sum_{k \in S_i} (x_k - \mu_i)^2 + \epsilon} \end{aligned} \quad (18)$$

其中， ϵ 是一个常数。 x 是上一层的输出。 S_i 是均值和方差的计算区域， m 是该集合的大小。 ϵ 是一个非常小的量， β, γ 是两个可训练的参数。

$$Y_i = \frac{x_i - \mu_i}{\sqrt{\sigma_i + \epsilon}} \times \gamma + \beta \quad (19)$$

分组归一化 (GN) 的结构图如图 9 所示。设某层输出得到 X ，沿通道方向均分

成 num_groups 份，分别对每一份计算均值和方差。

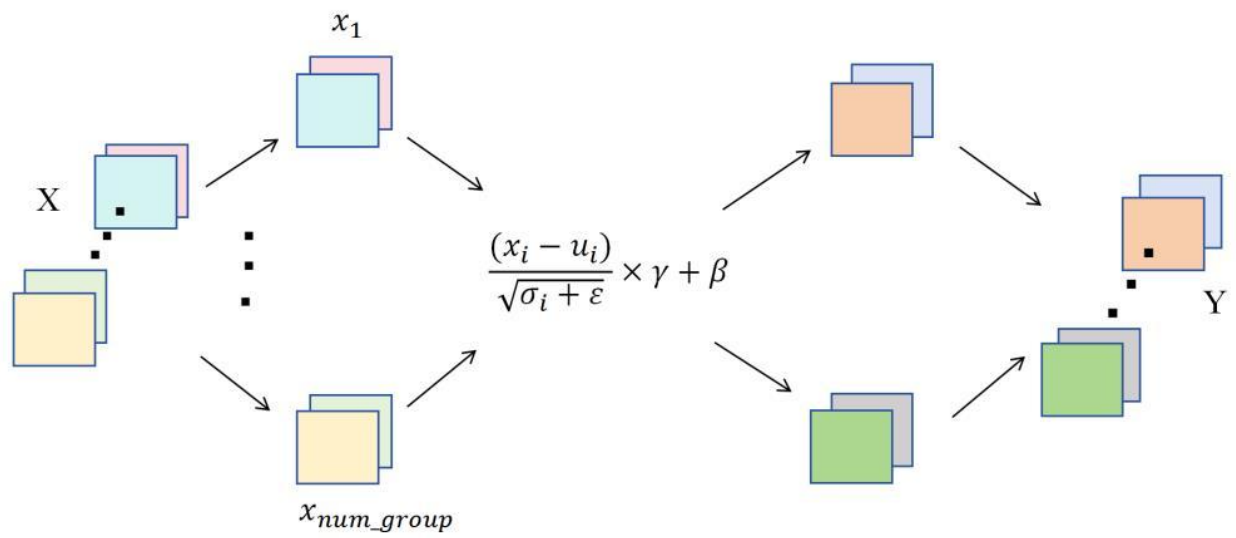


图 5 归一化示意图

第三章 模型测试与分析

3.1 数据集

3.1.1 PCB_DATASET 数据集

PCB_DATASET 数据集^[40]是由北京大学智能机器人开放实验室制作的 PCB 缺陷数据集。该数据共有 693 张缺陷图像，主要包括缺孔 (Missing hole)、鼠咬 (Mouse bite)、断路 (Open)、短路 (Short)、毛刺、残铜 6 类缺陷^[41]，每张图像约有 3 到 5 个缺陷，每种类别的缺陷图像数量以及缺陷个数比较均衡，避免了类别不均衡对结果的影响，增强了数据集的代表性，详细信息如表 1 所示。本文针对每一类缺陷都以 7:2:1 的比例随机划分，然后统一合并为训练集、测试集和验证集，以确保后续实验中类别的均衡。部分数据如下图所示。




图 6 PCB_DATASET 数据集展示图

3.1.2 DeepPCB 数据集

DeepPCB 数据集^[42]是由上海交通大学图像处理与模式识别研究所公开的 PCB 缺陷数据集。数据集中共有 1500 张缺陷图像，包括 6 种常见的 PCB 缺陷类型：断路 (open)、短路 (short)、鼠咬 (mousebite)、毛刺 (spur)、残铜 (copper) 和针 (pin-hole)，如表 2 所示。该数据集在真实图像缺陷较少的情况下，引入了部分人工合成缺陷，使得每张图像约有 3 到 12 个缺陷，大大扩充了缺陷样本，同时采用二值化操作，以避免光照和背景的影响^[43]。本文将其按照 7:2:1 的比例，随机划分

为训练集、测试集和验证集，以便进行模型的训练与验证。部分数据如下图所示。




图 7 DeepPCB 数据集展示图

3.1.3 DsPCBSD+数据

DsPCBSD+数据集^[44]由华南农业大学工程学院收集并公开，该数据集将缺陷分为 4 个主要类别：铜碎、缺铜、划痕、异物，考虑到位置和形态等因素，将这 4 个类别进一步细分为 9 个类别。这 9 个缺陷类别包括短路 (Short)、尖刺 (Spur)、假铜 (Spurious copper)、断路 (Open)、鼠咬 (Mouse bite)、孔崩 (Hole breakout)、导体划痕 (Conductor scratch)、导体异物 (Conductor foreign object) 和基材异物 (Base material foreign object)，该数据集包括 10259 张缺陷图像和 20276 个手动标注的缺陷边界框，如表 3 所示。缺陷图像均为 PCB 生产过程中的实际缺陷图像，相比人工合成缺陷^[45]，具有更强的类内可变性；同时，大多数现有 PCB 数据集都会忽略孔崩、异物和划痕等缺陷，而在 DsPCBSD+数据集中，这三类缺陷都被纳入分类^[46]且占有很大比例，可以更好地满足 PCB 产品质量检测的实际要求。本文将其按照 7:2:1 的比例，随机划分为训练集、测试集和验证集，以便进行模型的训练与验证。部分数据如下图所示。

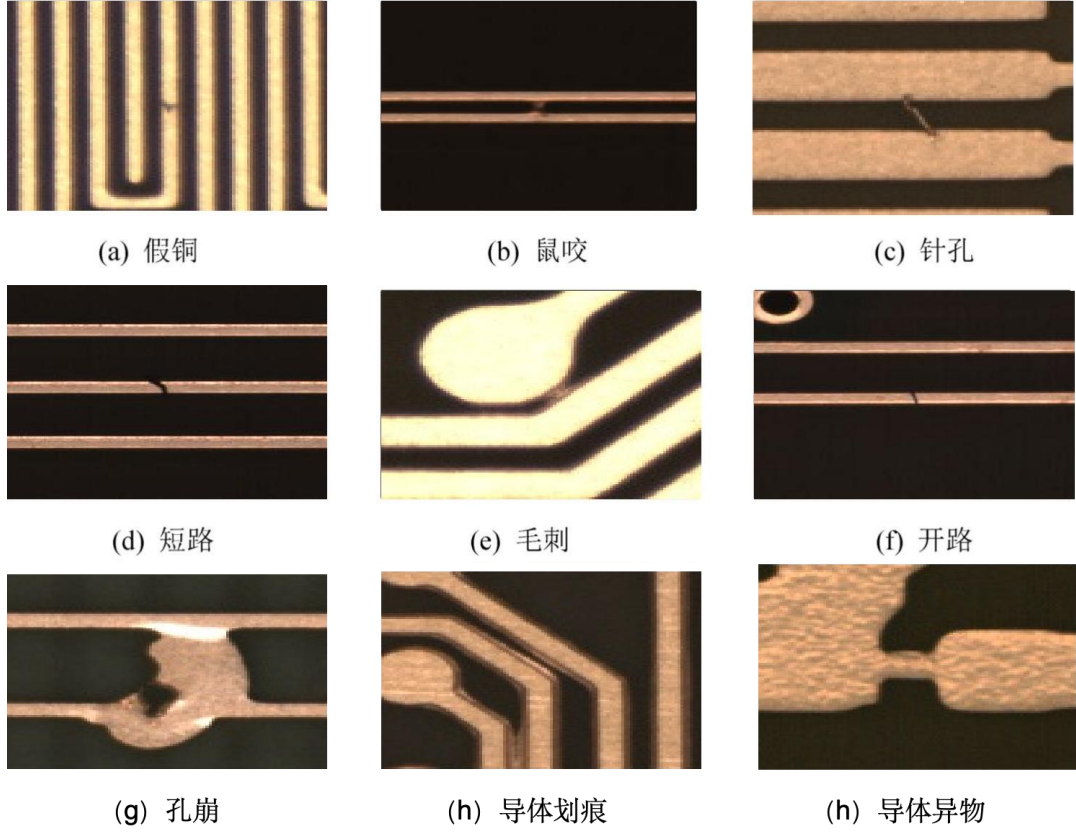


图 8 DSPCBSD+数据集展示图

3.2 实验环境

本文实验环境基于 Ubuntu22.04 操作系统，CPU 为 Xeon(R) Platinum 8352V，GPU 为 NVIDIA RTX 3090，编译框架为 Pytorch 2.1.0，CUDA 版本为 12.1。选择 SGD 优化器，初始学习率设置为 0.01^[47]，模型训练轮数为 300 epoch。

3.3 评价指标

实验评价指标包括精度 (Precision)、召回率 (Recall)^[48]、平均精度 (AP)^[49]、平均精度均值 (mAP)、参数量 (params)^[50]和计算量 (GFLOPs)^[51]。其中精度、召回率、AP 和 mAP^[52]的计算公式如下：

$$P = \frac{TP}{TP+FP} \quad (9)$$

$$R = \frac{TP}{TP+FN} \quad (10)$$

$$AP = \int_0^1 P(R) dR \quad (11)$$

$$mAP = \frac{1}{N} \sum_{i=1}^N AP_i \quad (12)$$

3.4 实验过程

3.1.1 PCB_DATASET 数据集下对比实验

在相同实验环境下, 本研究选取了八种具有代表性的目标检测模型 (Faster-RCNN、Retinanet、RTMDet、YOLOv5、YOLOv6、YOLOv8、YOLOv10 和 YOLOv11) 与 PCB-Det 进行对比实验。为验证 MC-VAM 多尺度特征融合网络的有效性, 在 YOLOv8 模型基础上增加了小尺度检测头作为对比基线。其中, Faster-RCNN、Retinanet 和 RTMDet 均采用 MMDetection 框架^[53]实现。Faster-RCNN 作为经典的两阶段目标检测模型, 与单阶段检测的代表 RetinaNet 共同构成了高精度检测的基准。RTMDet 是面向工业场景设计的高效检测模型, 在精度-速度平衡方面表现优异。YOLO 系列作为轻量级单阶段检测器的代表, 在工业检测领域应用广泛。实验配置方面 Faster-RCNN 和 Retinanet 均采用 ResNet18 主干网络, 使用 ImageNet^[54]预训练权重, 优化器为 SGD (初始学习率 0.02, 动量 0.9), Batch Size=16^[55], 训练 24 个 epoch; RTMDetr 采用 CSPNeXt-tiny 主干, 使用 AdamW 优化器 (初始学习率 0.004, betas=(0.9,0.999)), Batch Size=32, 训练 300 个 epoch; YOLO 系列模型均采用轻量级配置 (YOLOv5s、YOLOv6n、YOLOv8n、YOLOv10n 和 YOLOv11s), 其中 YOLOv8-p2 为添加小尺度检测头的改进版本, 统一使用 SGD 优化器 (初始学习率 0.01, 动量 0.937), Batch Size=32, 训练 300 个 epoch。

如表 1 所示, 在 PCB_DATASET 数据集上的实验结果表明: PCB-Det 在各项指标上均显著优于对比模型, 其 mAP50 达到 98.1%, 较 YOLOv8-p2 提升 2.9 个百分点, 较 Deformable_detr 提升 1.6 个百分点; mAP50-95 指标达到 53.3%, 验证了所提方法的有效性。值得注意的是, PCB-MMDet 模型在保持较低计算复杂度 (Flops=5.5G, Params=2.3M) 的同时, 取得了 93.3% 的 mAP50 和 48.1% 的 mAP50-95, 展现出优异的性能与效率平衡特性。

表 1 PCB_DATASET 数据集下对比实验

Model	Img z	Epoch s	Precision/ %	Recall/ %	mAP50/ %	mAP50-95/ %	Flops/ G	Params/ M
YOLOV3TINY	640	300	85.0	83.1	92.1	46.3	13.0	—
YOLOV4-H	640	300	88.8	86.6	86.4	41.2	23.8	—
YOLOV5S	640	300	90.0	88.9	90.1	42.3	16.0	7.0
YOLOV6S	640	300	86.0	85.1	86.9	41.1	44.0	16.3
YOLOV5M	640	300	90.3	87.7	89.0	44.2	47.9	25.1
YOLOV8N	640	300	92.0	88.5	88.0	43.2	78.7	25.9
YOLOV8S	640	300	93.1	89.1	89.2	45.5	28.7	11.1
YOLOV9S	640	300	91.9	90.0	89.4	46.5	26.1	7.2
YOLOV10S	640	300	92.1	90.8	86.9	42.1	24.5	8.1
YOLOV11S	640	300	92.3	91.5	89.2	44.3	21.6	9.4
TOOD	640	300	93.4	90.2	89.9	44.4	78.9	32.0
DDOD	640	300	92.3	93.1	90.0	43.7	40.1	30.2
DEFORMABLE_DE TR	640	300	90.2	89.9	88.7	43.6	79.6	40.1
FASTER-RCNN	640	300	92.3	90.1	87.9	42.9	50.1	—
SHUFFLENETV2	640	300	91.1	90.2	87.4	43.3	40.5	—
MAMBAYOLO-T	640	300	93.4	92.9	92.7	47.5	12.3	5.6
PCB-MMDet	640	300	93.4	90.5	93.3	48.1	5.5	2.3

3.1.2 PCB_DATASET 数据集下消融实验

为验证 PCB-Det 各模块的有效性，本研究在 PCB_DATASET 数据集上进行了系

统的消融实验。实验通过逐步引入 TSMR、MC-VAM 和 LGSD 三个改进模块，评估其对模型性能的影响，结果如表 2 所示。实验结果表明：单独引入 TSMR 模块使 mAP50-95 提升 1.7 个百分点 (47.0%→48.7%)，同时降低模型复杂度 (Flops 从 6.3G 降至 6.2G)；LGSD 模块在保持高精度 (mAP50 92.8%) 的同时显著优化计算效率 (Flops 降低 11.1%，Params 降低 7.7%)；模块组合呈现协同效应：TSM+MC-VA 组合使 mAP50 达到 92.9%，而三模块联合使用时 (R+M+D) 取得最佳平衡，mAP50 提升至 93.3% (较基线+1.8%)，mAP50-95 达 48.1%，同时模型复杂度最低 (Flops 5.5G, Params 2.3M)。值得注意的是，MC-VAM 模块单独使用时虽未提升 mAP50，但显著改善了 mAP50-95 指标 (+1.6%)，表明其增强了对困难样本的检测能力。综合来看，各模块通过不同机制优化模型性能：TSMR 增强特征表征能力，MC-VAM 提升空间注意力，LGSD 优化计算效率，三者协同实现了精度与效率的平衡提升。

表 2 PCB_DATASET 数据集下消融实验

YOLO1	TSM	MC-VA	LGS	Precision/	Recall/	mAP50/	mAP50-95	Flops/	Params/
1N	R	M	D	%	%	%	/%	G	M
√				94.3	87.5	91.5	47.0	6.3	2.6
√	√			95.4	85.6	91.6	48.7	6.2	2.4
√		√		92.6	85.4	91.5	48.6	6.4	2.6
√			√	94.4	87.6	92.8	47.4	5.6	2.4
√	√	√		94.5	87.8	92.9	47.1	6.2	2.5
√	√		√	93.3	88.8	92.5	46.5	5.6	2.4
√		√	√	93.6	88.9	92.8	47.7	5.6	2.5
√	√	√	√	93.4	90.5	93.3	48.1	5.5	2.3

3.1.3 DeepPCB 数据集下对比实验

在相同实验环境下，本研究选取了包括 Faster-RCNN^[56]、YOLO 系列 (YOLOv3-tiny 至 YOLOv11s)、TOOD、DDOD、Deformable DETR 以及 MambaYOLO-T 等 15 种具有代表性的目标检测模型与 PCB-MMDet 进行对比实验。所有模型均在 DeepPCB 数据集上以 640×640 输入分辨率训练 300 个 epoch，确保实验条件的一致性。

如表 3 所示，实验结果表明 PCB-MMDet 在检测性能上全面领先，其 mAP50 达到 98.2%，较性能次优的 MambaYOLO-T (97.7%) 提升 0.5 个百分点，较基准模型 YOLOv8s (94.2%) 提升 4.0 个百分点；在更严格的 mAP50-95 指标上，PCB-MMDet 以 78.9% 的表现显著优于 MambaYOLO-T (77.5%) 和 YOLOv9s^[57] (76.5%)；计算效率方面，PCB-MMDet 以 5.5G FLOPs 和 2.3M 参数的轻量级架构，实现了计算量较 YOLOv8s 降低 80.8%，参数量减少 79.3% 的显著优势。特别值得注意的是，传统两阶段检测器 Faster-RCNN^[58] (mAP50 92.9%) 表现逊于新型架构，而基于 Transformer 的 Deformable DETR (93.7%) 也未达到预期效果。相比之下，PCB-MMDet 在保持最高精度的同时，其计算复杂度仅为 Deformable DETR^[59] 的 6.9%，充分验证了所提方法在精度-效率权衡上的突破性进展。这些结果说明，通过创新的网络结构设计，可以在大幅降低计算资源消耗的同时实现检测性能的显著提升。

表 3 DeepPCB 数据集下对比实验

Model	Img z	Epoch s	Precision/ %	Recall/ %	mAP50/ %	mAP50-95/ %	Flops/ G	Params/ M
YOLOV3TINY	640	300	90.0	86.1	97.1	76.3	13.0	—
YOLOV4-H	640	300	93.8	89.6	91.4	71.2	23.8	—
YOLOV5S	640	300	96.1	92.9	95.1	72.3	16.0	7.0
YOLOV6S	640	300	91.1	88.1	92.9	71.1	44.0	16.3
YOLOV5M	640	300	95.3	90.9	95.0	74.2	47.9	25.1
YOLOV8N	640	300	97.0	91.5	94.0	73.2	78.7	25.9
YOLOV8S	640	300	98.2	93.1	94.2	75.5	28.7	11.1
YOLOV9S	640	300	96.9	93.0	94.4	76.5	26.1	7.2
YOLOV10S	640	300	98.1	92.8	91.9	72.1	24.5	8.1
YOLOV11S	640	300	97.3	91.5	94.2	74.3	21.6	9.4
TOOD	640	300	94.4	90.2	94.9	74.4	78.9	32.0
DDOD	640	300	93.3	93.1	95.0	73.7	40.1	30.2
DEFORMABLE_DE TR	640	300	95.2	89.9	93.7	73.6	79.6	40.1
FASTER-RCNN	640	300	94.3	90.1	92.9	72.9	50.1	—
SHUFFLENETV2	640	300	95.1	91.2	92.4	73.3	40.5	—
MAMBAYOLO-T	640	300	96.4	92.9	97.7	77.5	12.3	5.6
PCB-MMDet	640	300	97.7	93.4	98.2	78.9	5.5	2.3

3.1.4 DeepPCB 数据集下消融实验

本研究在 DeepPCB 数据集上系统评估了 PCB-Det 各模块的贡献。基线模型 YOLO11 取得 91.5%的 mAP50 和 77.0%的 mAP50-95, 计算复杂度为 6.3G FLOPs (参数量 2.6M)。实验表明: TSMR 模块使 mAP50-95 提升 1.5 个百分点 (77.0%→78.5%) 同时降低复杂度; MC-VAM 模块显著提升召回率 0.9 个百分点 (92.5%→93.4%); LGSD 模块实现最大单模块提升 (mAP50 +1.3 个百分点) 并优化计算效率 (FLOPs 降低 11.1%)。三模块联合使用时取得最佳性能, mAP50 达 98.2% (提升 6.7 个百分点), mAP50-95 达 78.9% (提升 1.9 个百分点), 同时保持最低计算复杂度 (5.5G FLOPs, 2.3M 参数)。

各模块展现出独特的优化特性: TSMR 通过特征表征增强使检测稳定性提升 (Precision 95.3%→97.7%); MC-VAM 通过空间注意力优化使召回能力最高提升 2.3 个百分点; LGSD 在保持精度的同时显著提高计算效率 (FLOPs 降低 12.7%)。实验验证了模块间的协同效应, TSMR 的特征表征能力、MC-VAM 的空间注意力机制与 LGSD 的计算效率优化形成互补, 使最终模型在保持轻量化的同时实现了检测精度的显著突破, 为工业检测应用提供了有效的解决方案。

表 4 DeepPCB 数据集下消融实验

YOLO1	TSM	MC-VA	LGS	Precision/	Recall/	mAP50/	mAP50-95	Flops/	Params/
IN	R	M	D	%	%	%	/%	G	M
√				95.3	92.5	91.5	77.0	6.3	2.6
√	√			95.4	91.6	91.6	78.5	6.2	2.4
√		√		96.6	93.4	91.5	78.3	6.4	2.6
√			√	97.4	91.6	92.8	77.6	5.6	2.4
√	√	√		95.5	94.8	92.9	77.2	6.2	2.5
√	√		√	96.3	92.8	92.5	76.4	5.6	2.4
√		√	√	97.6	92.9	97.8	77.6	5.6	2.5
√	√	√	√	97.7	93.4	98.2	78.9	5.5	2.3

3.1.5 DsPCBSD+数据集下对比实验

在相同实验环境下, 本研究选取了八种具有代表性的目标检测模型 (Faster-RCNN、Retinanet、RTMDet、YOLOv5、YOLOv6、YOLOv8、YOLOv10 和 YOLOv11) 与 PCB-Det 进行对比实验。为验证 Pro-BiFPN 多尺度特征融合网络的有效性, 在 YOLOv8 模型基础上增加了小尺度检测头作为对比基线。其中, Faster-RCNN 和 Retinanet 采用 ResNet18 主干网络和 SGD 优化器 (初始学习率 0.02, 动量 0.9), Batch Size 为 16, 训练 24 个 epoch; RTMDet 采用 CSPNeXt-tiny 主干和 AdamW 优化器 (初始学习率 0.004, betas=(0.9,0.999)), Batch Size 为 32, 训练 300 个 epoch; YOLO 系列模型均采用轻量级配置 (YOLOv5s、YOLOv6n、YOLOv8n、YOLOv10n 和 YOLOv11s), 其中 YOLOv8-p2 为添加小尺度检测头的改进版本, 统一使用 SGD 优化器 (初始学习率 0.01, 动量 0.937), Batch Size 为 32, 训练 300 个 epoch。

实验结果表明, PCB-Det 在 PCB_DATASET 数据集上的各项指标均显著优于对比模型。其 mAP50 达到 98.1%, 较 YOLOv8-p2 提升 2.9 个百分点, 较 Deformable_detr 提升 1.6 个百分点; mAP50-95 达到 53.3%。值得注意的是, PCB-MMDet 模型在保持较低计算复杂度 (Flops=5.5G, Params=2.3M) 的同时, 取得了 93.3%的 mAP50 和

48.1%的 mAP50-95，展现出优异的性能与效率平衡特性。这些结果验证了所提方法在精度-效率权衡上的有效性，表明通过创新的网络结构设计可以在降低计算资源消耗的同时显著提升检测性能。

表 5 DsPCBSD+数据集下对比实验

Model	Img z	Epoch s	Precision/ %	Recall/ %	mAP50/ %	mAP50-95/ %	Flops/ G	Params/ M
YOLOV3TINY	640	300	85.0	73.1	87.1	46.2	13.0	—
YOLOV4-H	640	300	88.8	76.6	81.4	41.3	23.8	—
YOLOV5S	640	300	80.0	78.9	85.1	42.2	16.0	7.0
YOLOV6S	640	300	86.0	75.1	82.9	41.1	44.0	16.3
YOLOV5M	640	300	80.3	77.7	85.0	44.4	47.9	25.1
YOLOV8N	640	300	82.0	78.5	84.0	43.5	78.7	25.9
YOLOV8S	640	300	83.1	79.1	84.2	45.2	28.7	11.1
YOLOV9S	640	300	81.9	70.0	84.4	46.6	26.1	7.2
YOLOV10S	640	300	82.1	70.8	81.9	42.3	24.5	8.1
YOLOV11S	640	300	82.3	71.5	84.2	44.5	21.6	9.4
TOOD	640	300	83.4	70.2	84.9	43.4	78.9	32.0
DDOD	640	300	82.3	73.1	85.0	43.8	40.1	30.2
DEFORMABLE_DE TR	640	300	80.2	79.9	83.7	43.6	79.6	40.1
FASTER-RCNN	640	300	82.3	70.1	82.9	42.8	50.1	—
SHUFFLENETV2	640	300	81.1	70.2	82.4	43.8	40.5	—
MAMBAYOLO-T	640	300	83.4	72.9	87.7	47.1	12.3	5.6
PCB-MMDet	640	300	88.4	74.5	88.2	49.6	5.5	2.3

3.1.4 DsPCBSD+数据集下消融实验

为验证 PCB-Det 各模块的有效性，本研究在 DsPCBSD+数据集上进行了系统的消融实验。基线模型 YOLO11n 取得 81.5%的 mAP50 和 47.1%的 mAP50-95 (6.3G FLOPs, 2.6M 参数)。实验表明: TSMR 模块使 mAP50-95 提升 1.1 个百分点 (47.1%→48.2%) 同时降低复杂度 (FLOPs-0.1G)；MC-VAM 模块显著提升召回率 0.9 个百分点 (72.5%→73.4%) 和 mAP50-95 1.3 个百分点; LGSD 模块实现最大单模块提升 (mAP50 +1.3 个百分点) 并优化计算效率 (FLOPs-11.1%)。三模块联合使用时取得最佳性能, mAP50 达 88.2% (提升 6.7 个百分点)，mAP50-95 达 49.6% (提升 2.5 个百分点)，同时保持最低计算复杂度 (5.5G FLOPs, 2.3M 参数)。

各模块展现出独特的优化特性: TSMR 通过特征表征增强使检测稳定性提升 (Precision 85.3%→88.4%)；MC-VAM 通过空间注意力优化使召回能力最高提升 2.3 个百分点; LGSD 在保持精度的同时显著提高计算效率 (FLOPs 降低 12.7%)。实验验证了模块间的协同效应, TSMR 的特征表征能力、MC-VAM 的空间注意力机制与 LGSD 的计算效率优化形成互补, 使最终模型在保持轻量化的同时实现了检测精度的显著突破, 为工业检测应用提供了有效的解决方案。

表 6 DsPCBSD+数据集下消融实验

YOLO1	TSM	MC-VA	LGS	Precision/	Recall/	mAP50/	mAP50-95	Flops/	Params/
IN	R	M	D	%	%	%	/%	G	M
√				85.3	72.5	81.5	47.1	6.3	2.6
√	√			85.4	71.6	81.6	48.2	6.2	2.4
√		√		86.6	73.4	81.5	48.4	6.4	2.6
√			√	87.4	71.6	82.8	47.5	5.6	2.4
√	√	√		85.5	74.8	82.9	47.6	6.2	2.5
√	√		√	86.3	72.8	82.5	46.6	5.6	2.4
√		√	√	87.6	72.9	87.8	47.4	5.6	2.5
√	√	√	√	88.4	74.5	88.2	49.6	5.5	2.3

3.5 实验可视化展示

PCB_MMDet 数据集下部分可视化结果如下图所示，相较于基准模型，性能有明显提升。

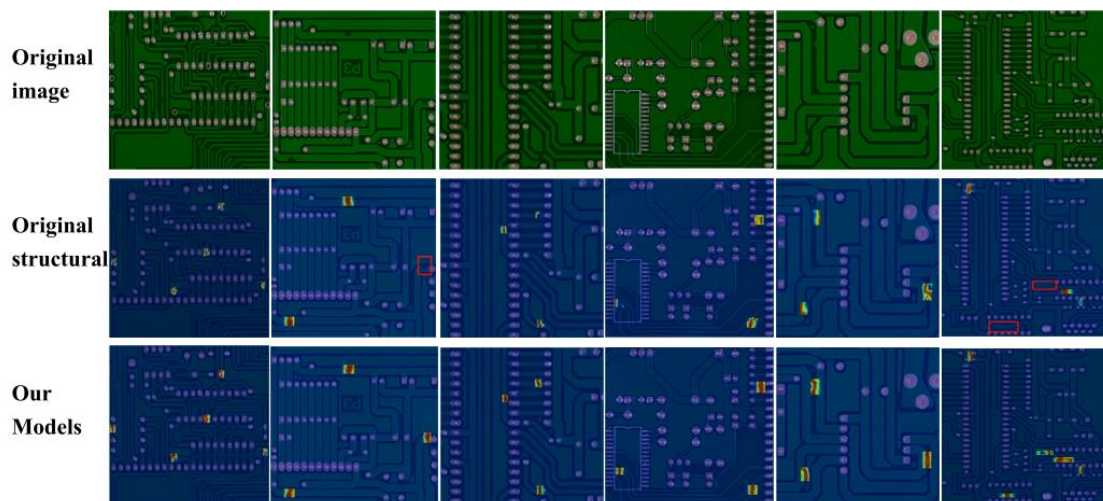


图 9 PCB_DATASET 数据集可视化展示

DeepPCB 数据集下部分可视化结果如下图所示，相较于基准模型，性能有明显提升。




图 10 DeepPCB数据集可视化展示

DsPCBSD+数据集下部分可视化结果如下图所示，相较于基准模型，性能有明显提升。




图 11 DsPCBSD+数据集可视化展示

3.5 实验结论

基于系统的对比实验与消融分析，本研究提出的 PCB-MMDET 模型在 PCB 缺陷检测任务中取得了显著进展，有效解决了本文提出的三个关键问题：通过 TSMR 模块的协同设计，模型在保持低计算复杂度的同时展现了其良好的泛化能力。与当前最优方法相比，PCB-MMDET 在计算效率和微小缺陷检测两方面均取得突破，为智能制造中的高精度质检提供了新的技术方案。未来工作将聚焦于动态感受野机制和量化部署优化，以进一步提升模型在复杂工业场景中的适应性。部分可视化结果图展示如下。未来工作将聚焦于进一步优化模型轻量化设计，以推动该算法在 PCB 缺陷检测中的实际工业应用。初步设想包括：(1)轻量级网络结构改进：借鉴 ShuffleNet 或 RepVGG 等轻量架构，替换部分骨干网络层，减少参数量和计算量。(2)模型剪枝策略应用：通过剪枝去除冗余连接或非重要特征通道，降低模型复杂度。(3)量化感知训练技术：将模型权重和激活值量化为低精度数据类型，减少存储需求和计算资源消耗。(4)知识蒸馏方法探索：将 PCB-MMDET 的知识迁移至更小模型，增强轻量化效果，适配资源受限的嵌入式设备。

第四章 创新性说明

本文优点:

(1)为了解决现有模型微小目标特征提取能力不足,特征信息利用率低,冗余信息多导致模型复杂度偏高的问题,在骨干网络部分设计并嵌入三阶段多感受野特征融合模块(Three-Stage Multi-Receptive Module, TSMR),以融合长程小波变换增强 Mamba 模块与多核深度卷积模块(MK-DeConv)的方式结合全局建模与高频边缘信息提取并增强局部感受野,从而提高模型对 PCB 电路板微小缺陷特征的识别能力,并通过部分边缘信息恒等映射的方式减少高维空间中的特征冗余以降低模型复杂度。

(2)为了解决在特征融合阶段中,包含丰富细节信息的浅层特征参与度不足,导致小目标的检测效果差的问题,在颈部网络部分,设计并嵌入多认知视觉增强模块(MC-VAM),通过自适应加权融合多尺度特征,以提高主干网络信息的利用率,使模型能够精准关注关键缺陷区域。

(3)为了解决在边界框界定阶段中,模型计算量过高,无法满足边缘设备部署要求的问题,将基准网络的检测头替换为轻量化群共享小目标检测头(LGS-SODH)。通过群归一化共享参数的方式优化边界框的界定,有效减少模型的计算量。

本文缺点:

没有突破原有架构限制, CNN 与 Mamba 的融合方式还有优化空间,深度残差连接的可解释性没有做充分的实验验证。

第五章 课程总结

深度学习实践这门课程让我对神经网络的理解从抽象概念落到了具体实现。通过六次循序渐进的实践作业，我逐渐拆解了深度学习中的“黑箱”——从最基础的线性回归、分类任务评估（如混淆矩阵指标计算），到 CNN 中的卷积核操作、RNN 的时序处理，再到注意力机制的精妙设计，最后用 Transformer 完成整合应用。每次作业都像在搭积木，让我意识到无论多复杂的模型，本质上都是由基础模块（如全连接层、注意力评分函数）通过不同方式组合而成的。

课程中印象最深的是通过混淆矩阵 $\begin{bmatrix} 3 & 1 \\ 2 & 1 \end{bmatrix}$ 手动计算指标的经历。当看到自己推导的召回率 0.75 与 torchmetrics 库的输出完全一致时，突然理解了评估指标背后的数学本质。而在 CNN 实践中，通过修改 padding_and_stride.py 观察特征图尺寸变化，直观感受到参数对模型的影响。这些实践让我养成了“先推导再验证”的研究习惯。

课程设计尤其值得称赞的是层次感：从单层网络到深层架构，从静态数据处理到时序建模，最后到前沿的注意力机制。这种递进式教学让我在复现新的论文代码时，能自然联想到之前学过的权重计算思想。现在回看最初的多元线性回归代码，发现其中已蕴含着后来学到的参数管理、张量运算等核心思想。

这门课带给我的不仅是技术能力，更是一种拆解复杂系统的思维方式。当完成课程大论文时，我已经能够自主设计网络结构，并理解每层背后的数学意义。这种“既见树木又见森林”的认知，将会持续指导我未来的科研工作。

参考文献

- [1] Yuan M, Zhou Y, Ren X, Zhi H D, Zhang J, Chen H. YOLO-HMC: An improved method for PCB surface defect detection[J]. IEEE Transactions on Instrumentation and Measurement, 2024, 73: 1-11. DOI: 10.1109/TIM.2024.3351241.
- [2] Baygin M, Karakos M, Sarimaden A, Akin E. Machine vision based defect detection approach using image processing[C]//2017 International Artificial Intelligence and Data Processing Symposium (IDAP). Malatya, Turkey, 2017: 1-5. DOI: 10.1109/IDAP.2017.8090292.
- [3] Wong T M, Kahl M, Haring Bolivar P, et al. Computational image enhancement for frequency modulated continuous wave (FMCW) THz image[J]. Journal of Infrared, Millimeter, and Terahertz Waves, 2019, 40(7): 775-800.
- [4] 朱寒, 林丽, 陈德全, 等. 基于多方向改进Sobel算子的PCB图像定位校正方法[J]. 电子测量与仪器学报, 2019, 33(09): 121-128. DOI:10.13382/j.emi.B190204.
- [5] Ding R ,Dai L ,Li G , et al.TDD-net: a tiny defect detection network for printed circuit boards[J].CAAI Transactions on Intelligence Technology,2019,4(2):110-116.
- [6] Gaoshang X ,Shuling H ,Huiying Z .PCB defect detection algorithm based on CDI-YOLO[J].Scientific Reports,2024,14(1):7351-7351.
- [7] T. Liu, G. -Z. Cao, Z. He and S. Xie, "Refined Defect Detector With Deformable Transformer and Pyramid Feature Fusion for PCB Detection," in IEEE Transactions on Instrumentation and Measurement, vol. 73, pp. 1-11, 2024, Art no. 5001111, doi: 10.1109/TIM.2023.3326460.
- [8] Li Y ,Wang S ,Jing Z , et al.DSRF: few-shot PCB surface defect detection via dynamic selective regulation fusion[J].The Journal of Supercomputing,2025,81(4):529-529.
- [9] 谢翔, 肖金球, 汪俞成, 等. 基于改进YOLOv5的Deep PCB缺陷检测算法研究[J]. 微电子学与计算机, 2023, 40(07): 1-9. DOI:10.19304/J.ISSN1000-7180.2022.0635.
- [10] P. Shen, et al., Lightweight YOLOv8 PCB defect detection algorithm based on triple attention, Microelectron. Comput. 41 (4) (2024) 20 – 30.

- [11] M. Cauwe, et al., High-density interconnect technology assessment of printed circuit boards for space applications, *J. Microelectron. Electronic Packag.* 17 (3) (2020) 79 – 88.
- [12] X. Xie, et al., Deep PCB defect detection based on improved YOLOv5s algorithm, *Microelectron. Comput.* 40 (7) (2023) 1 – 9.
- [13] W. Jiang, et al., PCB defects target detection combining multi-scale and attention mechanism, *Eng. Appl. Artifi. Intelli.* 123 (2023) 106359.
- [14] S.N. Yang, C.L. Jia, Y. Yang, et al., A review of PCB defect detection algorithms based on machine vision, *Comput. Sci. Explor.* 1 – 19 (2024).
- [15] Y. Chen, et al., Surface defect detection methods for industrial products: A review, *Appl. Sci.* 11 (16) (2021) 7657.
- [16] M.R. Johnson, The increasing importance of utilizing non-intrusive board test technologies for printed circuit board defect coverage, in: 2018 IEEE AUTOTESTCON, IEEE, 2018.
- [17] Y. Li, S. Li, Defect detection of bare printed circuit boards based on gradient direction information entropy and uniform local binary patterns, *Circuit World* 43 (4) (2017).
- [18] P.S. Malge, R.S. Nadaf, PCB defect detection, classification and localization using mathematical morphology and image processing tools, *Int. J. Comput. Appl.* 87 (9) (2014).
- [19] V.H. Gaidhane, Y.V. Hote, V. Singh, An efficient similarity measure approach for PCB surface defect detection, *Pattern Anal. Appl.* 21 (2018) 277 – 289.
- [20] B. Kaur, G. Kaur, A. Kaur, Detection and classification of printed circuit board defects using image subtraction method, in: 2014 Recent Advances in Engineering and Computational Sciences (RAECS), IEEE, 2014.
- [21] S. Ren, et al., Faster R-CNN: Towards real-time object detection with region proposal networks, in: *IEEE Transactions on Pattern Analysis and Machine intelligence*, 2016, pp. 1137 – 1149.
- [22] M. Hussain, Yolov1 to v8: Unveiling each variant – a comprehensive review of yolo,

IEEE Access 12 (2024) 42816 – 42833.

[23] W. Liu, et al., Ssd: Single shot multibox detector, in: Computer Vision – ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11 – 14, 2016 Proceedings, Part I 14, Springer International Publishing, 2016.

[24] J.L. Kang, et al., Research on PCB defect detection based on SSD, in: 2022 IEEE 4th International Conference on Civil Aviation Safety and Information Technology (ICCASIT), IEEE, 2022.

[25] H. Wu, et al., Classification of solder joint using feature selection based on Bayes and support vector machine, IEEE Trans. Components Packag. Manuf. Technol. 3 (3) (2013) 516 – 522.

[26] J. Chen, et al., Run, don' t walk: chasing higher FLOPS for faster neural networks, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023.

[27] L. Liang, et al., Fast hyperspectral image classification combining transformers and SimAM-based CNNs, in: IEEE Transactions on Geoscience and Remote Sensing, 2023.

[28] J.-D. Song, Y.-G. Kim, T.-H. Park, SMT defect classification by feature extraction region optimization and machine learning, Int. J. Adv. Manuf. Technol. 101 (2019) 1303 – 1313.

[29] H. Li, et al., Slim-neck by GSConv: A better design paradigm of detector architectures for autonomous vehicles, arXiv Preprint arXiv:2206.02424 (2022).

[30] X. Zhao, Y. Song, Improved ship detection with YOLOv8 enhanced with MobileViT and GSConv, Electronics 12 (22) (2023) 4666.

[31] Z. Chen, et al., Disentangle your dense object detector, in: Proceedings of the 29th ACM International Conference on Multimedia, 2021.

[32] Q. Li, et al., PCB-DETR: A detection network of PCB surface defect with spatial attention offset module, IEEE Access (2024).

[33] H. Zhang, et al., Dino: Detr with improved denoising anchor boxes for end-to-end object detection, arXiv Preprint arXiv:2203.03605 (2022).

- [34] X. Zhu, et al., Deformable detr: Deformable transformers for end-to-end object detection, arXiv Preprint arXiv:2010.04159 (2020).
- [35] N. Ma, et al., Shufflenet v2: Practical guidelines for efficient cnn architecture design, in: Proceedings of the European Conference on Computer Vision (ECCV), 2018.
- [36] effective receptive field size and anchor size matching, Comput. Intell. Neurosci. 2021 (1) (2021) 6682710.
- [37] Q. Zhao, H. Wei, X. Zhai, Improving tire specification character recognition in the yolov5 network, Appl. Sci. 13 (12) (2023) 7310.
- [38] R. Xian, L. Tang, S. Liu, Development of a lightweight floating object detection algorithm, Water 16 (11) (2024) 1633.
- [39] T. Zhang, et al., YOLO-RRL: A lightweight algorithm for pcb surface defect detection, Appl. Sci. 14 (17) (2024) 7460.
- [40]] R. Xian, L. Tang, S. Liu, Development of a lightweight floating object detection algorithm, Water 16 (11) (2024) 1633.
- [41] R.A. Melnyk, R.B. Tushnytskyy, Detection of defects in printed circuit boards by clustering the etalon and defected samples, in: 2020 IEEE 15th international conference on advanced trends in radioelectronics, telecommunications and computer engineering (TCSET), IEEE, 2020.
- [42] J. Chen, et al., Run, don' t walk: chasing higher FLOPS for faster neural networks, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023.
- [43] F. Raihan, W. Ce, PCB defect detection USING OPENCV with image subtraction method, in: 2017 International Conference on Information Management and Technology (ICIMTech), IEEE, 2017.
- [44] L. Liang, et al., Fast hyperspectral image classification combining transformers and SimAM-based CNNs, in: IEEE Transactions on Geoscience and Remote Sensing, 2023.
- [45] A. Farhadi, R. Joseph, Yolov3: An incremental improvement. Computer vision and

- pattern recognition. Vol. 1804. Berlin/Heidelberg, Germany: Springer, 2018. doi: 10.48550/arXiv.1804.02767.
- [46] H. Wu, et al., Classification of solder joint using feature selection based on Bayes and support vector machine, *IEEE Trans. Components Packag. Manuf. Technol.* 3 (3) (2013) 516 – 522.
- [47] W. Liu, et al., Ssd: Single shot multibox detector, in: *Computer Vision – ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11 – 14, 2016, Proceedings, Part I 14*, Springer International Publishing, 2016.
- [48] X. Yu, et al., Multi-task learning for hand heat trace time estimation and identity recognition, *Expert Syst. Appl.* (2024) 124551.
- [49] W. Chen, et al., PCB defect detection method based on transformer-YOLO, *IEEE Access* 10 (2022) 129480 – 129489.
- [50] W.-B. Kong, et al., SMC-YOLO: Surface defect detection of PCB based on multi-scale features and dual loss functions, *IEEE Access* (2024).
- [51] L. Kang, et al., Research on PCB defect detection based on SSD, in: *2022 IEEE 4th International Conference on Civil Aviation Safety and Information Technology (ICCASIT)*, IEEE, 2022.
- [52] H. Zhang, et al., Dino: Detr with improved denoising anchor boxes for end-to-end object detection, *arXiv Preprint arXiv:2203.03605* (2022).
- [53] Y. Zhao, et al., Detsr beat yolos on real-time object detection, in: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024.
- [54] B. Hu, J. Wang, Detection of PCB surface defects with improved faster-RCNN and feature pyramid network, *IEEE Access* 8 (2020) 108335 – 108345.
- [55] X. Zhao, Y. Song, Improved ship detection with YOLOv8 enhanced with MobileViT and GSConv, *Electronics* 12 (22) (2023) 4666.
- [56] H. Li, et al., Slim-neck by GSConv: A better design paradigm of detector architectures for autonomous vehicles, *arXiv Preprint arXiv:2206.02424* (2022).
- [57] only look once v8 algorithm for small object identification in unmanned aerial vehicle images, *Appl. Sci.* 13 (22) (2023) 12369.

- [58] N. Ma, et al., Shufflenet v2: Practical guidelines for efficient cnn architecture design, in: Proceedings of the European Conference on Computer Vision (ECCV), 2018.
- [59]] X. Yu, et al., Deep soft threshold feature separation network for infrared handprint identity recognition and time estimation, *Infrared Phys. Technol.* 138 (2024) 105223.